Une porte de village qui apprend à faire attendre

Explication accessible du « contrôle d'admission stigmergique et de quorum »

`moderation-pipeline-prototype` — août 2026

Le problème. Certains litiges qui arrivent devant un système de modération sont réellement difficiles à trancher : chaque camp avance des arguments qui attaquent ceux de l'autre, et la méthode rapide et peu coûteuse censée les départager ne parvient à aucune conclusion nette. Dans ce cas, le système se rabat sur une méthode bien plus minutieuse, et bien plus coûteuse, pour démêler l'ensemble — une méthode utile, mais que l'on ne souhaite pas offrir gratuitement, sur simple demande, à quiconque la sollicite. Le défaut se situe dans la manière dont cette méthode coûteuse se déclenche. Dans la conception d'origine, la toute première personne à se présenter avec un argument d'apparence plausible fait basculer le dossier vers le traitement coûteux, immédiatement. C'est exactement le genre de règle qu'un attaquant adore : se présenter une seule fois, en masse, avec un tas d'arguments fabriqués, et la porte coûteuse s'ouvre gratuitement, autant de fois qu'on le souhaite.

L'idée. Le remède emprunte deux mécanismes à la nature, et il vaut la peine de les prendre l'un après l'autre, car chacun résout une moitié différente du problème.

Le premier mécanisme est la façon dont une colonie de fourmis retient quel chemin vers la nourriture mérite d'être suivi. Une fourmi ne vote pas une fois pour toutes ; elle dépose une odeur en marchant, et cette odeur s'estompe régulièrement, à moins que d'autres fourmis, arrivées indépendamment, n'empruntent le même chemin et ne la raniment. Un chemin ne reste marqué que s'il continue de gagner des passages frais, venus de fourmis différentes — une seule fourmi qui fait des allers-retours sur sa propre piste toute la journée laisse, en pratique, une trace tout aussi faible qu'un unique passage. Transposé ici : chaque dossier disputé porte un score qui s'affaiblit un peu à chaque pas de l'horloge, et un nouvel argument ne relève ce score que d'un tout petit peu s'il provient d'une source ayant déjà pris la parole récemment. Une préoccupation véritablement nouvelle, indépendante, maintient un dossier en vie ; le même plaignant répétant la même chose en boucle, non.

Le second mécanisme est la façon dont les bactéries décident, en colonie, du moment où elles sont assez nombreuses pour agir ensemble — un mécanisme appelé détection de quorum. Aucune bactérie isolée ne prend cette décision seule ; toute la colonie lit un signal chimique partagé qui reflète la densité déjà atteinte, et relève ou abaisse en conséquence son seuil collectif d'action. Transposé ici : la barre qu'un dossier doit franchir pour atteindre le traitement coûteux n'est pas fixe. Elle s'élève automatiquement dès que ce traitement coûteux est déjà occupé par d'autres dossiers — exactement comme une salle de restaurant devient plus difficile à intégrer à mesure qu'elle se remplit, sans que personne à l'entrée ne décide consciemment de durcir les critères.

L'assemblage. Le score d'un dossier disputé s'estompe comme une odeur de piste qui s'évente, n'est relevé que par un renforcement d'apparence nouvelle, est plafonné pour qu'aucun instant isolé d'activité ne puisse le faire bondir au-delà d'une limite raisonnable, et doit franchir une barre qui monte avec l'occupation déjà en cours du traitement coûteux. Une seule salve d'indignation fabriquée, aussi massive soit-elle, ne peut faire franchir à un score plafonné et décroissant un seuil en un seul instant — il n'y a tout simplement pas assez de poids autorisé à entrer dans un seul pas de l'horloge, quel que soit le nombre de voix factices qui se présentent d'un coup.

Ce qui a réellement été mesuré, non simplement espéré. Le mécanisme a été

confronté à son prédécesseur — la règle d'admission instantanée — sous plusieurs formes d'attaque, et la comparaison a été menée honnêtement, y compris sur le cas où le nouveau mécanisme ne l'emporte pas complètement. Une salve unique, de taille quelconque, d'une seule voix à cinq mille, arrivant en un instant : entièrement bloquée, à chaque fois, là où l'ancienne règle laissait passer chacune d'entre elles. La même salve soutenue très longtemps depuis une seule source repérable : toujours entièrement bloquée, et de façon démontrable, non pas seulement « bloquée jusqu'ici dans les essais menés ». Deux cents litiges distincts, chacun frappé d'une salve isolée, aux côtés de quinze litiges authentiques en croissance organique au même moment : l'ancienne règle laissait passer toutes les attaques et admettait aussi tous les litiges authentiques, pour un coût de traitement réel de 215 dossiers ; le nouveau mécanisme n'en laissait passer aucune tout en admettant les quinze litiges authentiques, pour un coût réel de 15 dossiers — quatre-vingt-treize pour cent de travail en moins imposé au traitement coûteux. L'exception honnête, énoncée sans détour plutôt que dissimulée : un attaquant patient, disposé à fabriquer une identité fraîche, jamais réutilisée et d'apparence indépendante à chaque pas de l'horloge, pendant plusieurs pas d'affilée, n'est pas complètement arrêté. Cet attaquant finit par passer tout de même, au prix d'un effort et d'un temps environ cinq fois supérieurs à ce que l'ancienne règle lui aurait coûté. Le mécanisme transforme une attaque gratuite en attaque coûteuse ; il ne la rend pas impossible, et cette limite est rapportée ici plutôt que laissée à la découverte, plus tard, par quelqu'un d'autre.

Ce que ce mécanisme ne fait délibérément pas. Il ne dit rien de qui a *raison* dans le litige lui-même — ce jugement reste entièrement confié au traitement coûteux qu'il protège, une fois le dossier admis. Il suppose qu'il existe un coût réel, même modeste, à se présenter comme une voix toute nouvelle et indépendante à chaque pas ; si cette hypothèse cesse de tenir pour un attaquant donné, le retard imposé constitue toute la défense, non un filet posé sur quelque chose de plus solide. Et le tour de l'estompage plafonné d'une part, celui de la barre qui monte d'autre part, pris chacun tout à fait à part, sont individuellement bien connus en dehors de la biologie aussi — le premier ressemble à un limiteur de débit ordinaire, utilisé partout en informatique ; le second ressemble à une technique de réseau vieille de plusieurs décennies, destinée à désengorger une file avant qu'elle ne déborde. Ce qu'une recherche approfondie dans la littérature de recherche pertinente n'a pas fait apparaître, c'est cette combinaison précise des trois éléments, gardant spécifiquement ce type de recours coûteux et difficile à paralléliser. C'est là l'affirmation restreinte qui est faite, et seulement dans la mesure où cette recherche a été menée à fond — non une prétention que personne, nulle part, n'aurait jamais combiné ces idées auparavant.

Pourquoi cela mérite d'être consigné. Rien, dans le traitement coûteux lui-même, n'a eu besoin de changer ; le correctif se loge entièrement à la porte qui le précède. Les ingrédients pris individuellement — un score qui s'estompe, un plafond sur ce qu'un seul instant peut apporter, une barre qui monte avec l'affluence — sont chacun empruntés à des domaines forts de leur propre longue expérience, biologique aussi bien que informatique. Ce qui est rapporté ici, c'est la manière dont ils se composent, testée honnêtement contre l'attaque qu'ils devaient contrer, avec le cas où le succès n'est que partiel énoncé aussi clairement que les cas de succès complet.