Une porte d'admission à décroissance pondérée, à escompte d'indépendance des sources et à seuil adaptatif de charge, pour un étage d'argumentation NP-complet

Note d'ingénierie de prototype — `moderation-pipeline-prototype`

Août 2026

Résumé

Un pipeline d'escalade qui bascule vers l'énumération d'extensions préférées dans un cadre d'argumentation abstraite (Dung, 1995) lorsque la sémantique fondée ne tranche pas hérite de la complexité, dans le pire cas, de ce recours : l'acceptation crédule d'une extension préférée est NP-complète. Une règle d'admission qui ouvre l'accès à cet étage coûteux dès qu'un dossier stagne et que le délai d'attente expire est exploitable au coût attaquant $O(1)$: une seule salve d'arguments plausibles et mutuellement attaquants suffit à forcer l'admission. Nous spécifions, implémentons et soumettons à une évaluation adversariale une porte de remplacement, construite par composition de trois éléments : un score de pression d'escalade propre à chaque dossier, qui décroît géométriquement à chaque pas de temps (transposition directe de la règle d'évaporation des phéromones utilisée en optimisation par colonies de fourmis), un renforcement plafonné par pas et ramené à un poids quasi nul lorsqu'il provient d'une source déjà vue dans une fenêtre récente (codant une exigence de corroboration provenant de sources réellement indépendantes, et non simplement d'un délai écoulé), et un seuil d'admission qui lui-même s'élève avec le taux d'occupation courant de l'étage coûteux à l'échelle du système (un signal agrégé, dépendant de la densité, dans l'esprit du *quorum sensing*). Nous dérivons sous forme close le comportement en régime permanent et le temps minimal d'admission de cette porte à partir de la récurrence linéaire qui la gouverne, et vérifions cette dérivation contre la simulation déployée : une salve en un seul pas de temps, de taille quelconque (1 à 5000), est bloquée sans condition ; une inondation persistante issue d'une même cohorte est bloquée structurellement, son score en régime permanent étant provablement incapable d'atteindre le seuil ; une inondation persistante utilisant à chaque pas une source fraîche et d'apparence non liée n'est pas bloquée mais voit son admission retardée du coût attaquant $O(1)$ à $O(5)$ tours soutenus et diversifiés en identité, conformément à la prédiction analytique à un pas près. Une recherche dédiée d'antériorités, en seize requêtes, n'a trouvé aucun précédent direct pour cette composition précise à trois éléments gardant l'accès à un étage d'argumentation NP-complet ; les transferts biologiques pris isolément, et le domaine général du contrôle d'admission, sont en revanche bien documentés, et cités comme tels plutôt que passés sous silence. Le résultat est rapporté comme une défense partielle honnêtement bornée — une augmentation réelle et quantifiée du coût attaquant, non une clôture — cohérente avec le résidu identifié pour la variante la plus difficile, celle d'un attaquant patient et diversifiant son identité.

1 Le problème

Un pipeline de modération de contenu à quatre étages achemine vers un cadre d'argumentation abstraite (*abstract argumentation framework*, AF) [1] les dossiers sur lesquels un étage de classification sélective s'est abstenu : les arguments et les attaques sont construits à partir des déclarations et réfutations brutes du dossier, et l'*extension fondée* du cadre — le plus petit point fixe de la fonction caractéristique F_{AF}, atteignable en temps polynomial — en constitue la sortie principale, tractable. Lorsque deux groupes d'arguments qui s'attaquent

mutuellement laissent l'extension fondée vide (le motif dit du « diamant de Nixon »), le pipeline se rabat sur l'énumération des *extensions préférées*, dont le problème d'acceptation crédule est NP-complet [2]. Ce recours est une échappatoire nécessaire, délibérément bornée, non un défaut de conception : sans lui, un dossier bloqué ne se résoudrait jamais.

La vulnérabilité se situe à la frontière de l'*admission*, non dans la machinerie d'argumentation elle-même. Si un dossier stagnant est admis à l'étage coûteux dès que son délai d'escalade expire, un attaquant capable de produire, en une seule salve, des arguments plausibles et mutuellement attaquants force l'admission au coût $O(1)$: aucune persistance, aucun signal d'identité distinguable, rien que du volume à un instant donné. L'objectif de l'attaquant n'est pas de gagner le débat — la porte d'intégrité des preuves du scénario A ferme déjà cette voie [10] — mais de faire payer à la plateforme, à répétition et à faible coût, la taxe NP-complète.

2 La porte

2.1 Source de conception

Deux mécanismes biologiques ont motivé la construction, utilisés ici comme source génératrice de la conception, et non comme justification apportée après coup à un mécanisme déjà bâti.

Renforcement stigmergique. Chez les fourmis en quête de nourriture, les pistes de phéromones s'évaporent en continu ; la règle de mise à jour canonique de Dorigo et Stützle s'écrit $\tau \leftarrow (1-\rho)\tau$, appliquée à chaque itération [3]. Les expériences du pont double de Deneubourg ont établi le fait complémentaire que ce qui compte dans la force d'une piste est le renforcement apporté par des fourmis explorant *indépendamment* les unes des autres, et non un seul individu repassant plusieurs fois sur son propre chemin ; AntNet, de Di Caro et Dorigo, impose la même exigence d'indépendance dans un cadre de systèmes distribués, en bâtissant sa règle de renforcement sur une « communication indirecte et non coordonnée » entre agents qui « collectent l'information en explorant le réseau » [4].

Détection de quorum. Chez les bactéries, le *quorum sensing* régule l'expression génique en fonction de la densité de population, détectée par un signal agrégé, propre à l'environnement partagé (la concentration d'un auto-inducteur), plutôt que par l'état privé d'une cellule isolée [5]. L'idée structurelle transposée ici est étroite et précise : subordonner une admission collective à un signal d'occupation partagé et agrégé, non au seul score local d'un dossier pris isolément.

2.2 Spécification formelle

Définition 1 (État d'admission)**.** *Un dossier c possède un score $S_c(t) \in \mathbb{R}_{\geq 0}$, initialisé à 0 au premier contact. À chaque pas de temps discret $t = 0, 1, 2, \ldots$, l'ensemble des événements de renforcement observés pour c est un multiensemble d'identifiants de cohorte-source $R_c(t) \subseteq \mathcal{K}$.*

Définition 2 (Contribution par pas)**.** *Pour chaque cohorte $k \in R_c(t)$ (dédupliquée à l'intérieur du pas), soit* $\mathrm{frais}(k, c, t) = 1$ *si k n'a pas renforcé c au cours des w derniers pas (la fenêtre d'indépendance), et* 0 *sinon. La contribution brute du pas est*

$$r_c(t) = \sum_{k \in R_c(t)} \big[\mathrm{frais}(k, c, t) \cdot 1 + \big(1 - \mathrm{frais}(k, c, t)\big) \cdot \delta\big], \qquad 0 < \delta \ll 1,$$

plafonnée à un montant fixe par pas γ : la contribution appliquée est $\hat{r}_c(t) = \min(r_c(t), \gamma)$.

Définition 3 (Mise à jour du score)**.**

$$S_c(t) = (1-\rho)\, S_c(t-1) + \hat{r}_c(t), \qquad \rho \in (0, 1].$$

Définition 4 (Seuil d'admission adaptatif à la charge)**.** *Soit $L(t)$ le nombre de dossiers occupant l'étage coûteux au pas t (un signal partagé et agrégé, propre au système entier, non une propriété*

du seul dossier c), θ_0 le seuil de base, κ la sensibilité à la charge, et C une capacité de référence. Le seuil d'admission est

$$\Theta(t) = \theta_0\Big(1 + \kappa\frac{L(t)}{C}\Big).$$

Le dossier c est admis à l'étage coûteux au premier pas t_* tel que $S_c(t_*) \geq \Theta(t_*)$.

Cette spécification compose trois mécanismes indépendamment motivés : une décroissance géométrique (évaporation stigmergique), une contribution plafonnée par pas et escomptée selon l'indépendance des sources (renforcement stigmergique exigeant la diversité des sources), et un seuil adaptatif à la charge (détection de quorum). Chaque élément, pris isolément, recombine un principe déjà connu — décroissance plus plafond par pas est structurellement un limiteur de débit de type *leaky bucket*/EWMA, et un seuil qui s'élève avec la charge est structurellement proche de *Random Early Detection* [6]. L'objet de la composition est la contribution spécifique, revendiquée comme telle : faire garder ensemble, par ces trois mécanismes, l'accès à un étage d'argumentation NP-complet, en exigeant un sourçage indépendant — et non le simple écoulement du temps — pour qu'un renforcement compte à plein poids.

2.3 Comportement en forme close

Considérons le pire cas pour un attaquant capable de livrer, à chaque pas, la contribution appliquée maximale c_* (soit γ, si une source d'apparence fraîche est disponible à chaque pas, soit $\delta\gamma$, si la même source se répète). En déroulant la récurrence à partir de $S_c(0) = 0$:

$$S_c(n) = c_* \sum_{i=0}^{n-1}(1-\rho)^i = c_*\,\frac{1-(1-\rho)^n}{\rho}.$$

Proposition 1 (Plafond en régime permanent)**.** $\lim_{n\to\infty} S_c(n) = \dfrac{c_*}{\rho}$. *Si $\Theta \geq c_*/\rho$ à la charge en vigueur au moment du contact, aucune suite de renforcements plafonnés au taux c_* ne peut jamais admettre c, quelle que soit sa durée.*

Argument. Immédiat à partir de la forme close : $(1-\rho)^n \to 0$ quand $n \to \infty$ pour $\rho \in (0, 1]$, si bien que $S_c(n)$ croît de façon monotone vers c_*/ρ par valeurs inférieures (chaque terme de la somme est positif ou nul). Si le plafond n'atteint pas Θ, aucun n fini ne le peut non plus, puisque $S_c(n) < c_*/\rho$ pour tout n fini. □

C'est ce mécanisme qui rend l'inondation persistante issue d'une même cohorte *structurellement* bloquée, et non pas simplement retardée : un renforcement répété depuis une seule source est escompté à $c_* = \delta\gamma$, dont le plafond $\delta\gamma/\rho$ est conçu pour rester sous θ_0.

Proposition 2 (Nombre minimal de pas jusqu'à l'admission)**.** *Si $\Theta < c_*/\rho$ (le plafond atteint bien le seuil), le nombre minimal de pas jusqu'à l'admission, en supposant que l'attaquant sature $c_* = \gamma$ à chaque pas depuis une source d'apparence fraîche, est*

$$n_{\min} = \frac{\ln(1-\Theta\rho/\gamma)}{\ln(1-\rho)}.$$

Argument. On résout $S_c(n) \geq \Theta$ pour le plus petit entier n, en utilisant la forme close de la proposition 1 avec $c_* = \gamma$: $\gamma(1-(1-\rho)^n)/\rho \geq \Theta \iff (1-\rho)^n \leq 1-\Theta\rho/\gamma$. Comme $0 < 1-\rho < 1$, prendre le logarithme des deux membres inverse l'inégalité : $n\ln(1-\rho) \leq \ln(1-\Theta\rho/\gamma)$, et diviser par la quantité négative $\ln(1-\rho)$ donne $n \geq \ln(1-\Theta\rho/\gamma)/\ln(1-\rho)$. □

Corollaire 1 (La tension d'étalonnage)**.** *Notons $x = \Theta\rho/\gamma$ (évalué en $\Theta = \theta_0$, à charge nulle). La condition d'admission d'un dossier authentique (une probabilité moyenne de renforcement*

indépendant $p \gtrsim x$ par pas, pour que le mécanisme reste utilisable en pratique) et la durée minimale de l'inondation soutenue nécessaire à l'attaquant, $n_{\min}(x)$ selon la proposition 2, sont gouvernées par la même quantité x. Abaisser x pour faciliter l'admission des dossiers authentiques raccourcit nécessairement $n_{\min}$, et relever x pour allonger $n_{\min}$ durcit nécessairement le seuil pour les dossiers authentiques. Aucun choix des constantes ajustables ne permet de relâcher l'un sans resserrer l'autre.

Le corollaire 1 est énoncé et présenté comme une limitation authentique de cette classe de modèles, non résolue par le réglage des paramètres : c'est une propriété structurelle de toute porte construite à partir d'une décroissance géométrique et d'un plafond fixe par pas, indépendante des constantes particulières retenues.

3 Évaluation adversariale

La porte ($\rho = 0{,}10$, $\gamma = 1{,}0$, $w = 3$ pas, $\delta = 0{,}05$, $\theta_0 = 4{,}0$, $\kappa = 0{,}5$, $C = 5$) a été confrontée à l'ancienne référence statique — admettre sans condition dès le premier renforcement, une fois le dossier stagnant et son délai d'attente expiré — selon cinq scénarios adversariaux (code source et tests complets dans le dépôt du prototype accompagnant ce document ; résultats ci-dessous ré-exécutés indépendamment pour la rédaction du présent article, `pytest tests/test_admission_control.py -v -s`, 6/6 réussis, 0,38 s).

Variante d'attaque	Référence statique	Porte défendue
Salve en un seul pas, taille 1 à 5000, structure de cohorte quelconque	100 % admis, pas 0	**0 % admis, sans condition**
Inondation persistante, même cohorte, 200 pas	Admis au pas 0	**Structurellement inatteignable** (plafond $0{,}5 < \theta{=}4{,}0$)
Inondation persistante, cohorte usurpée (source fraîche à chaque pas)	Admis au pas 0	Admis au pas 4 (**retard** $\times 5$, conforme à $n_{\min} \approx 4{,}85$)
Pulvérisation : 200 dossiers, salve isolée chacun, 15 litiges authentiques concurrents	215/215 admis (100 % de réussite pour l'attaque)	**15/215 admis** (0 % de réussite, 93,0 % d'admissions en moins)
12 campagnes soutenues synchronisées, adaptation à la charge activée ou non	—	étalement sur 0 pas (désactivée) → **étalement sur 13 pas** (activée)

TABLE 1 – Résultats mesurés, référence statique contre porte défendue. Un contrôle de cohérence (20 litiges authentiques, renforcés organiquement) a confirmé l'admission de 20 dossiers sur 20 par la porte défendue : les chiffres de 0 % ci-dessus traduisent bien une discrimination réelle, non un rejet en bloc.

Le résultat obtenu contre la cohorte usurpée est le résidu honnête, non vaincu : un attaquant disposé à soutenir une campagne réellement diversifiée en identité (des cohortes fraîches, jamais réutilisées, à chaque pas) finit tout de même par réussir, à un coût relevé de $O(1)$ à $O(n_{\min})$. Ce résultat est présenté comme une défense partielle, non comme une clôture, exactement ce que prédit la proposition 1 pour tout taux de contribution c_* dont le plafond dépasse Θ.

Deux bogues d'implémentation, découverts en cours de test et signalés plutôt que dissimulés, méritent d'être consignés comme des leçons d'ingénierie transposables à cette classe de mécanismes : (1) une première version sommait les contributions d'une même cohorte *à l'intérieur* d'un seul pas avant déduplication, ce qui permettait à une inondation d'une même cohorte d'atteindre le plafond par le seul volume intra-pas, contournant l'escompte d'indépendance —

corrigé en dédupliquant les cohortes par pas avant application du plafond ; (2) une première version des tests adversariaux ne libérait jamais les dossiers admis du signal de charge, produisant un seuil qui ne cessait de croître et affamait les dossiers authentiques ultérieurs, pur artefact de simulation — corrigé en modélisant un temps de séjour borné à l'étage coûteux, non en assouplissant l'assertion du test. La leçon générale : dans une porte de style *quorum sensing*, le signal de charge doit être lié à une occupation réelle et se vidant effectivement, non à un compteur cumulatif d'admissions.

4 Antériorités

Une recherche dédiée en seize requêtes (journal complet conservé dans le document de spécification du dépôt accompagnant) a couvert le contrôle d'admission d'inspiration biologique, la littérature sur le *quorum sensing* appliqué à l'informatique, la littérature sur le déni de service contre les cadres d'argumentation et la complexité des attaques ciblant l'extension préférée, ainsi que les systèmes d'arbitrage et de justice décentralisée. Aucun article n'a été trouvé composant les trois éléments ci-dessus (renforcement pondéré par décroissance et escompté selon l'indépendance des sources ; plafond strict par pas ; seuil adaptatif à la charge de type quorum) comme porte d'admission à un étage d'argumentation NP-complet.

Les transferts pris isolément sont, en revanche, bien documentés, et cités comme tels : le renforcement par décroissance de phéromone relève de l'optimisation par colonies de fourmis la plus classique [3, 4] ; une combinaison décroissance-plus-plafond, prise seule, est structurellement un limiteur de débit de type *leaky bucket*/EWMA, primitive standard et non biologique ; un seuil d'admission qui s'élève avec la charge est structurellement proche de *Random Early Detection* [6] ; le *quorum sensing* a déjà été transposé à l'informatique, pour le partitionnement en grappes [7] et pour l'agrégation d'anomalies de sécurité multi-agents [8], ni l'un ni l'autre n'étant une porte d'admission pour un étage d'argumentation. Le résultat adjacent le plus proche trouvé pour le patron général de transfert biologie-informatique employé ici est une défense contre les inondations par système immunitaire artificiel [9], qui repose sur la détection d'anomalies par entropie du trafic et une mise en quarantaine immunitaire — un mécanisme différent, non fondé sur une décroissance de pression d'admission.

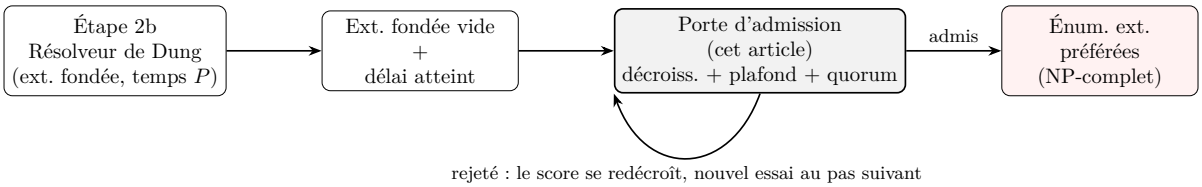
5 Menaces à la validité

L'évaluation est une simulation synthétique à pas discrets, non un test contre une dynamique d'arrivée réelle en temps continu ; la traduction de la granularité du pas retenue ici vers l'unité de temps d'un déploiement réel reste un travail d'ingénierie non vérifié. La condition de cohorte usurpée accorde à l'attaquant une capacité généreuse (une identité fraîche et structurellement indétectable à chaque pas) ; le plafond réel de diversité d'identité qu'un détecteur effectif imposerait n'est pas modélisé ici. Cette porte suppose que les couches de détection de coordination et d'intégrité des preuves présentes ailleurs dans le pipeline sont inefficaces dans le pire cas testé ici (la condition de cohorte usurpée du scénario B) ; en pratique, ces couches relèveraient encore le coût réel de l'attaquant, mais cette composition n'est pas mesurée dans le présent document. Aucune affirmation n'est faite selon laquelle cette porte, ou le pipeline dans lequel elle s'insère, résoudrait le problème authentiquement ouvert de juger un contenu réellement inédit au regard d'une spécification contestée — une question orthogonale et structurellement indécidable, que ce mécanisme ne touche pas.

6 Conclusion

La porte d'admission spécifiée ici ferme la variante la plus économique et la plus réaliste d'une attaque par épuisement de ressources contre un recours d'argumentation NP-complet — des salves en un seul pas, de taille quelconque, concentrées sur un dossier ou pulvérisées sur plusieurs — et relève, sans l'éliminer, le coût de la variante la plus difficile, patiente et diversifiée en identité, de $O(1)$ à $O(n_{\min})$ tours soutenus, sous la paramétrisation testée. Cette composition n'a pas été retrouvée dans une recherche dédiée d'antériorités à seize requêtes, tandis que ses transferts biologiques et informatiques constitutifs ont chacun, individuellement, été trouvés et cités comme précédents réels, non présentés comme novateurs. La tension d'étalonnage du corollaire 1 est rapportée comme une propriété inhérente à cette classe de modèles, non comme une limitation propre aux constantes choisies ici.

A Placement dans le pipeline



Références

[1] P. M. Dung. On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, 77(2) :321–357, 1995.

[2] J. K. Fichte, S. A. Gaggl, D. Rusovac, et al. Complexity of claim-centric abstract argumentation frameworks. *AAAI*, 2024.

[3] M. Dorigo et T. Stützle. *Ant Colony Optimization*. MIT Press, 2004.

[4] G. Di Caro et M. Dorigo. AntNet : Distributed stigmergetic control for communications networks. *Journal of Artificial Intelligence Research*, 9 :317–365, 1998.

[5] M. B. Miller et B. L. Bassler. Quorum sensing in bacteria. *Annual Review of Microbiology*, 55 :165–199, 2001.

[6] S. Floyd et V. Jacobson. Random early detection gateways for congestion avoidance. *IEEE/ACM Transactions on Networking*, 1(4) :397–413, 1993.

[7] X. Wang. A quorum sensing inspired algorithm for dynamic clustering. *arXiv :1303.3934*, 2013.

[8] M. E. Fioravanti II. Digital quorum sensing for self-organizing malware / a quorum sensing pattern for multi-agent self-organizing security systems. Florida Institute of Technology, 2012–2013.

[9] Adaptive artificial immune networks for mitigating DoS flooding attacks. *arXiv :2402.07714*.

[10] Spécification interne : *A four-stage content-moderation escalation pipeline : formal specification, attack analysis, and prototype verdict*, `moderation-pipeline-prototype/SPEC.md`, 2026.